



APLICACIÓN DEL APRENDIZAJE AUTOMÁTICO EN LA INDUSTRIA ENERGÉTICA

Práctica 1: Predicción de la radiación solar en plantas fotovoltaicas



AGENDA

1

- **Objetivos**

2

- **Problema**

3

- **Datos**

4

- **Desarrollo de la práctica**
 - Actividades
 - Tareas
 - Entregables
 - Planificación

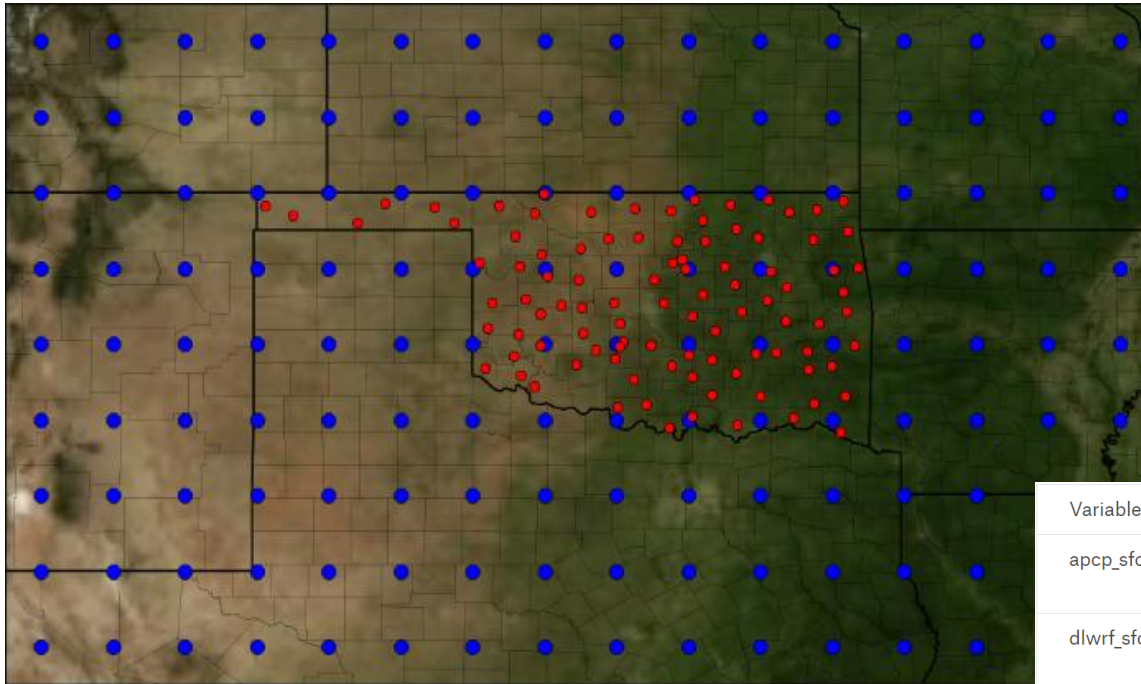
Objetivos

- Conocer un contexto de aplicación real.
- Ejercitarnos en el análisis de datos y la implementación de algoritmos de regresión en **MLR** para adquirir criterio en la aplicación de los mismos, tanto para **métodos de entrenamiento simples como avanzados**.
- Explorar las actividades de la **metodología** del AA para construir y comparar modelos.
- <https://www.kaggle.com/c/ams-2014-solar-energy-prediction-contest/data> (datos modificados)

Problema

- A finales del 2015 se estimó que el **23,7%** de la energía eléctrica mundial se produjo mediante fuentes de **energía renovables**
- Uno de los mayores problemas que tiene la energía solar es su **variabilidad e incertidumbre**. Las empresas productoras necesitan una estimación diaria para las siguientes 24 horas. Por ello es importante tener una predicción lo más acertada posible.
- Nuestro principal objetivo será **predecir la radiación solar** diaria en una planta solar de Oklahoma a partir de **predicciones de variables meteorológicas del día anterior**, usando **MLR**.

Problema



ROJO Estaciones
fotovoltaicas

AZUL Rejilla de
predicciones meteorológicas
(NWP Numerical Weather
Prediction)

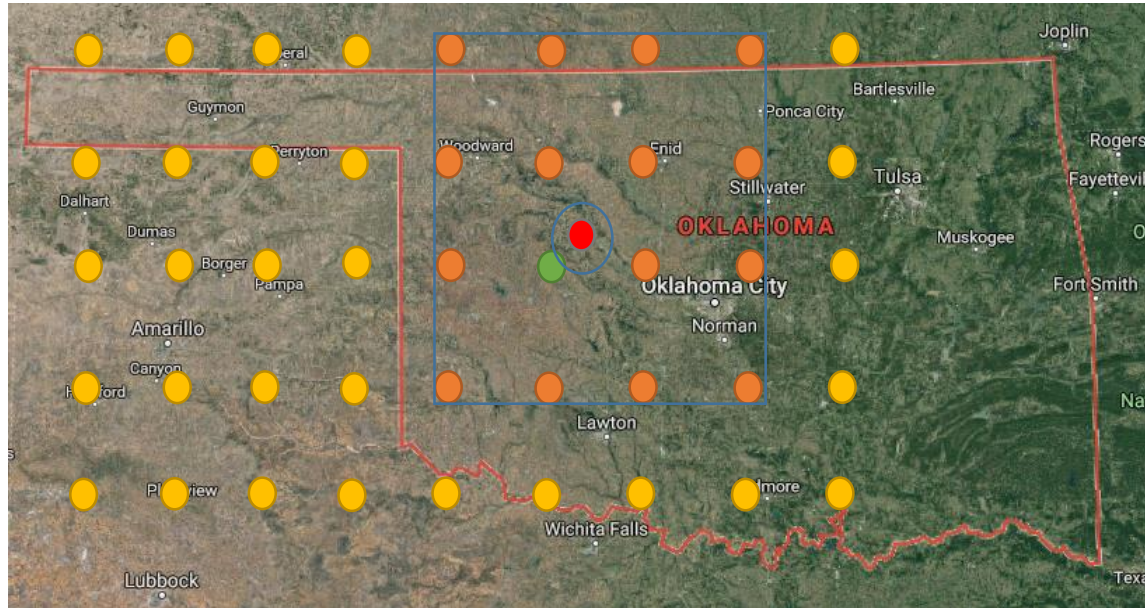
Problema consiste en encontrar modelos de aprendizaje automático f , de tal manera que:

- Si atributos = variables meteorológicas predichas el día anterior para el día siguiente (mediante NWP)
- Y *salida* = radiación solar acumulada día siguiente
- Ocurra que: $salida \sim f(atributos)$

Variable	Description
apcp_sfc	3-Hour accumulated precipitation at the surface
dlwrf_sfc	Downward long-wave radiative flux average at the surface
dswrf_sfc	Downward short-wave radiative flux average at the surface
pres_msl	Air pressure at mean sea level
pwat_eatm	Precipitable Water over the entire depth of the atmosphere
spfh_2m	Specific Humidity at 2 m above ground
tcdc_eatm	Total cloud cover over the entire depth of the atmosphere
tcopc_eatm	Total column-integrated condensate over the entire atmosphere

Datos

Rejilla predicción. Sistema GFS (Global Forecast System)



- Rejilla completa
- Nodo más cercano
- Central solar

- La superficie terrestre está dividida horizontalmente en una malla que es de 35 o 70 kilómetros² por celda; en la vertical la atmósfera está dividida en 64 capas y en la dimensión temporal, el GFS produce predicciones de 3 en 3 horas vista hasta las primeras 192 horas (H+3,6,9...192) y después con una resolución de 12 horas (H+204,216, 228...384).
- Variables-> temperatura media, máxima, mínima, precipitación, nubosidad, etc.
- Modelo con cobertura global cuyas predicciones están disponible gratuitamente .

[Global Forecast System - Wikipedia, la enciclopedia libre](#)

Datos

Simulando in GFS

- **Atributos de entrada:** predicciones del día siguiente de 15 variables meteorológicas. Los datos han sido generados por una simulación de ecuaciones de la atmósfera denominada NWP (Numerical Weather Prediction).
- Dichas variables han sido generadas para cinco momentos del día siguiente: 12h, 15h, 18h, 21h, 24h UTC.
- Hay 15 variables, generadas para 5 momentos del día siguiente = **75 atributos de entrada**.
- Ej: *apcp_sf1_1* significa "3-Hour accumulated precipitation at the surface". Es una variable predicha para el primero de los momentos del día siguiente. *apcp_sf3_1* sería para el tercer momento del día siguiente.
- Ej: *dswrf_s2_1* significa "Downward short-wave radiative flux average at the surface".
- El significado de las variables está aquí: <https://www.kaggle.com/c/ams-2014-solar-energy-prediction-contest/data>.
- Importante: los datos que se van a utilizar en la práctica no son los originales, sino que tienen ligeras modificaciones.
- Es la última columna de los datos, y se denomina "**salida**". Es la radiación solar acumulada durante todo el día.

4. DESARROLLO DE LA PRÁCTICA

Actividades

- Vamos a suponer que estamos en una competición. Así, tenemos:
 - Un conjunto de datos disponibles (12 años) (disp_1.rds). Con ellos:
 - Haremos varias pruebas para obtener **el mejor modelo posible** (model selection). Esto incluye todo tipo de pruebas sobre actividades de la metodología: ¿cuál es el mejor método para preprocesar?, ¿cuál es el mejor método de construcción de modelos? ¿cuáles son los mejores hiper-parámetros para cada método? etc.
 - Obtendremos una estimación del comportamiento de lo que podría obtener el modelo en la competición.
 - Construiremos el modelo final con el que competiremos.
 - Un conjunto de datos para competir (2 años adicionales) (compet_1.rds), sin la variable de respuesta. Con ellos:
 - Aplicaremos el modelo final para obtener las predicciones que enviaríamos a la competición. Dado que realmente no hay tal competición, entregaréis las predicciones en un fichero.

Tareas

- Un conjunto de datos disponibles 1994-2003 (trainstxx.rds). Con ellos:
 - **Model selection: haremos varias pruebas para obtener el mejor modelo posible. Esto incluye todo tipo de pruebas sobre actividades de la metodología: ¿cuál es el mejor método para preprocesar?, ¿cuál es el mejor método de construcción de modelos? ¿cuáles son los mejores hiper-parámetros para cada método? etc.**
 - Obtendremos una estimación del comportamiento de lo que podría obtener el modelo en la competición.
 - Construiremos el modelo final con el que competiremos.

- Como comentamos antes, para hacer esta parte, disponemos de 9 años (desde el dato 1 hasta el 9*365).
- En general, lo que vamos a hacer en esta parte es un montón de experimentos, incluyendo ajuste de hiper-parámetros. Compararemos todos esos experimentos y nos quedaremos con el mejor. Para comparar todos los experimentos, usaremos los tres últimos años de los 9. Es decir usaremos los datos desde el 6*365+1 hasta el 9*365 para evaluar (validación) y comparar experimentos. Y desde el dato 1 hasta el 6*365 (6 años) para entrenar modelos.
- Para hacerlo, crearemos una tarea, con los datos de los 9 años.
- Usaremos como evaluación externa Holdout, pero queremos usar explícitamente los tres últimos años para evaluar y los seis primeros para entrenar. Así:

```
train_validation_partition <- rsmp("custom")
train_validation_partition$instantiate(mytask,
  train = list(1:(6*365)),
  test = list((6*365+1):mytask$nrow()))
```

El custom resampling no funciona al hacer ajuste de hiper-parámetros en mlr3 con AutoTuner\$new. Usad el siguiente desc_inner (sin hacer instantiate), en lugar del custom que había que usar originalmente:

```
source("ResamplingHoldoutOrder.R")
desc_inner <- rsmp("holdoutorder",ratio=6/9)
(Ver Ajuste Hiper-parámetros)
```

- Utilizaremos como métrica relative absolute error (RAE)

Actividades

- Un conjunto de datos disponibles 1994-2003 (trainstxx.rds). Con ellos:
 - Model selection: haremos varias pruebas para obtener el mejor modelo posible. Esto incluye todo tipo de pruebas sobre actividades de la metodología: ¿cuál es el mejor método para preprocesar?, ¿cuál es el mejor método de construcción de modelos? ¿cuáles son los mejores hiper-parámetros para cada método? etc.
 - **Obtendremos una estimación del comportamiento de lo que podría obtener el modelo en la competición.**
 - Construiremos el modelo final con el que competiremos.
- Para obtener esta estimación reservaremos los tres últimos años. Es decir, nos olvidamos de esos datos hasta casi el final de la práctica, cuando tengamos el mejor modelo posible. Esos datos son los que van desde el dato $(9*365+1)$ hasta el final $(12*365)$.
- Por tanto, para hacer la parte principal de la práctica (model selection) disponemos de 9 años (desde el dato 1 hasta el $9*365$).
- Utilizaremos como métrica relative absolute error (RAE)

Actividades

El objetivo principal de la práctica es obtener un modelo final que tenga el mínimo error posible.

1. Haremos EDA. Dado que la información a obtener es sencilla, prefiero que lo hagáis sin usar DataExplorer. Es importante determinar qué atributos son factores, cuales ordinales, si hay NAs, etc, para saber qué preprocesos realizar para cada método.
2. Determinación del mejor método de imputación y de escalado, usando únicamente knn.
3. Comparar varios métodos de entrenamiento:
 - reg.lm, knn, rpart, cubist, svm con kernel radial (gausiana)
 - Random Forest y Boosting
 - Todos ellos sin y con ajuste de hiper-parámetros (excepto reg.lm y cubist), para ver si el ajuste mejora el error.
4. Una vez elegido el método que funciona mejor:
 - Evaluar para estimar comportamiento futuro, usando los datos que al principio habíamos reservado para ello (los tres últimos años).
 - Construir el modelo final.
 - Usar el modelo final para calcular predicciones sobre el conjunto "compet_xx.rds"
5. Investigación adicional. Se trata de encontrar información sobre el método de ajuste de hiper-parámetros denominado "hyperband". Describidlo en la memoria usando vuestras palabras, y usadlo para ajustar hiper-parámetros de un método, el que elijáis, describiendo las ventajas que se observan al usarlo.

Entregables

Se pide **entregar** un fichero **zip** que contenga:

- el fichero o ficheros con el código R (script o .Rmd).
- el fichero de predicciones del modelo final sobre el conjunto `compet_xx.rds`
- el modelo final (se puede guardar en un fichero con `saveRDS`).
- una memoria describiendo los resultados y lo que se pida en el enunciado (el formato puede ser cualquier de pdf, doc, html).
- Un video de no más de 5 minutos exponiendo las conclusiones de la memoria y vuestra valoración sobre la práctica

Nota importante:

- Cada grupo debe usar la estación (punto rojo) que le corresponda (fichero adjunto práctica)
- Los resultados tienen que ser reproducibles. Como sabéis, para ello tenéis que usar `set.seed()` en los lugares apropiados. Pero en lugar de usar `set.seed(0)`, tenéis que usar `set.seed` con el NIA de uno de los miembros del grupo. Ejemplo, si vuestro NIA es 100345719, entonces tenéis que poner `set.seed(100345719)`.

Planificación

- Entrega: A través de Aula Global hasta el 25/11/22.
- Puntuación: sobre 4 puntos.
- Equipos de trabajo: Si se cambian los equipos de la práctica anterior comunicación por correo-e.
- Clases de prácticas:
 - 18/10.
 - 25/10.
 - 1/11: fiesta.
 - 8/11.
 - 15/11.
 - 22/11.
- Dudas fuera de clase a través de Aula global.